ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIÊN TIẾN CHẤT LƯỢNG CAO VÀ POHE

NHÓM 14
KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

ĐỀ BÀI:

Phân tích thu nhập của người trưởng thành theo điều tra dân số

Lớp: Kinh tế đầu tư CLC 66B
Giảng viên: Trần Đức Minh

HA NOI- 2026

THÀNH VIÊN

STT	Họ và tên	MSV	Mức độ hoàn thành
1	Nguyễn Minh Quỳnh Anh (Leader)	11241733	100%
2	Hoàng Khánh Huyền	11241780	100%
3	Ngô Thùy Dung	11243049	100%
4	Đặng Hương Ly	11244528	100%
5	Đỗ Phương Thảo	11248348	100%

BÌNH LUẬN

……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……

MỞ ĐẦU

1. Lý do lựa chọn đề tài

Trong bối cảnh dữ liệu ngày càng được ứng dụng rộng rãi trong nhiều lĩnh vực, phân tích dữ liệu trở thành công cụ quan trọng giúp khai thác thông tin, nhận diện xu hướng và hỗ trợ quá trình ra quyết định. Đặc biệt, việc phân tích các đặc điểm nhân khẩu học và nghề nghiệp có thể giúp làm rõ mối liên hệ giữa trình độ học vấn, công việc, thời gian lao động và mức thu nhập của mỗi cá nhân.

Bộ dữ liệu Adult Census Income cung cấp thông tin về các đặc điểm cá nhân như độ tuổi, giới tính, trình độ học vấn, nghề nghiệp, số giờ làm việc mỗi tuần và mức thu nhập. Đây là nguồn dữ liệu phù hợp để thực hành các kỹ thuật xử lý, khám phá và trực quan hóa dữ liệu, đồng thời tìm hiểu những yếu tố có thể liên quan đến mức thu nhập của người lao động.

Xuất phát từ những lý do trên, nhóm lựa chọn đề tài phân tích bộ dữ liệu Adult Census Income nhằm vận dụng kiến thức về khoa học dữ liệu vào một bài toán thực tế, qua đó rèn luyện kỹ năng xử lý dữ liệu, phân tích thống kê và trình bày kết quả trực quan.

2. Mục tiêu nghiên cứu

Mức thu nhập của cá nhân trong bộ dữ liệu Adult Census Income được chia thành hai nhóm: nhóm có thu nhập không vượt quá 50.000 USD/năm (<=50K) và nhóm có thu nhập trên 50.000 USD/năm (>50K). Việc phân tích mối liên hệ giữa hai nhóm thu nhập với các thuộc tính cá nhân và nghề nghiệp giúp nhận diện những đặc điểm có sự khác biệt về phân bố giữa nhóm thu nhập thấp và nhóm thu nhập cao. Cụ thể, nghiên cứu tập trung vào các khía cạnh sau:

- Độ tuổi (age): Xem xét sự phân bố độ tuổi giữa hai nhóm thu nhập, qua đó tìm hiểu liệu nhóm có thu nhập cao có xu hướng tập trung ở những độ tuổi nhất định hay không.
- Trình độ học vấn (education, education.num): Phân tích sự khác biệt về trình độ học vấn giữa hai nhóm, đánh giá mối liên hệ giữa mức độ học vấn và khả năng đạt được mức thu nhập cao hơn.
- Nghề nghiệp (occupation): So sánh tỷ lệ phân bố các nhóm nghề nghiệp theo mức thu nhập, xác định những ngành nghề có tỷ trọng người thu nhập trên 50K cao hoặc thấp.
- Số giờ làm việc mỗi tuần (hours.per.week): Khảo sát sự khác biệt về thời gian làm việc giữa hai nhóm, xem xét liệu nhóm thu nhập cao có làm việc nhiều giờ hơn hay không.
- Mức tăng vốn và lỗ vốn (capital.gain, capital.loss): Đánh giá sự khác biệt về các khoản tăng vốn và lỗ vốn giữa hai nhóm thu nhập.
- Các đặc điểm khác: Tiếp tục xem xét giới tính (sex), tình trạng hôn nhân (marital.status), tầng lớp lao động (workclass), mối quan hệ gia đình

(relationship), chủng tộc (race) và quốc gia xuất xứ (native.country) để có cái nhìn toàn diện hơn.

Thông qua các nội dung trên, nghiên cứu hướng đến việc nhận diện những thuộc tính có sự khác biệt đáng chú ý giữa hai nhóm thu nhập, làm cơ sở cho các phân tích và nhận xét tiếp theo.

3. Câu hỏi nghiên cứu

Nghiên cứu tập trung giải quyết các câu hỏi sau:

1. Bộ dữ liệu Adult Census Income có cấu trúc và đặc điểm như thế nào?
2. Dữ liệu tồn tại những vấn đề gì về chất lượng và cần được xử lý ra sao trước khi phân tích?
3. Đặc điểm về độ tuổi, trình độ học vấn, nghề nghiệp và thời gian làm việc của các cá nhân được thể hiện như thế nào?
4. Nghề nghiệp, số giờ làm việc mỗi tuần và mức tăng vốn (capital-gain) có những đặc điểm phân bố gì?
5. Các yếu tố được khảo sát có mối liên hệ như thế nào với mức thu nhập của cá nhân?

4. Phạm vi và phương pháp

4.1. Phạm vi nghiên cứu

Bài nghiên cứu sử dụng bộ dữ liệu Adult Census Income, tập trung phân tích các đặc điểm cá nhân và nghề nghiệp có mối liên hệ với nhóm thu nhập của người lao động tại Hoa Kỳ.

Biến mục tiêu là income, gồm hai nhóm: thu nhập không vượt quá 50.000 USD (<=50K) và thu nhập trên 50.000 USD (>50K). Các yếu tố được tập trung phân tích bao gồm độ tuổi, trình độ học vấn, giới tính, nghề nghiệp và số giờ làm việc mỗi tuần.

Phạm vi phân tích được giới hạn trong các quan sát có sẵn của bộ dữ liệu, không mở rộng thành nghiên cứu quan hệ nhân quả hoặc đánh giá mức thu nhập của toàn bộ lực lượng lao động hiện nay.

4.2. Phương pháp nghiên cứu

Nhóm sử dụng phương pháp phân tích dữ liệu định lượng, kết hợp các kỹ thuật thống kê mô tả, trực quan hóa và kiểm định giả thuyết.

- Thống kê mô tả: Sử dụng các chỉ tiêu như số lượng, tỷ lệ phần trăm, trung bình và trung vị để mô tả đặc điểm dữ liệu và so sánh hai nhóm thu nhập.
- Trực quan hóa: Sử dụng biểu đồ cột, biểu đồ phân phối, biểu đồ hộp (Boxplot) và bản đồ nhiệt tương quan (Heatmap) để thể hiện đặc điểm và mối quan hệ giữa các biến.
- Kiểm định Chi-square: Đánh giá mối liên hệ giữa các biến định tính, cụ thể là trình độ học vấn, giới tính, nghề nghiệp và nhóm thu nhập.

- Kiểm định Mann-Whitney U: So sánh phân phối độ tuổi và số giờ làm việc giữa hai nhóm thu nhập độc lập.
- Tương quan Spearman: Đánh giá mối tương quan đơn điệu giữa các biến định lượng, bao gồm cả biến thu nhập sau khi mã hóa nhị phân.

Các kiểm định thống kê sử dụng mức ý nghĩa (alpha=0,05). Kết quả được diễn giải dựa trên p-value và chỉ số cỡ ảnh hưởng phù hợp

PHẦN 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU

1.1. Nguồn gốc và quá trình thu thập

Nhóm sử dụng bộ dữ liệu Adult Census Income, được cung cấp trên nền tảng Kaggle tại đường dẫn: Adult Census Income - Kaggle.

Bộ dữ liệu được lưu dưới tên adult.csv và sử dụng trong môi trường Google Colab. Theo mã nguồn của nhóm, dữ liệu được đọc từ thư mục Google Drive: /content/drive/MyDrive/Adult_Census_Income/adult.csv

Sau khi tải và lưu trữ, nhóm sử dụng thư viện Pandas để đọc dữ liệu, kiểm tra cấu trúc và tiến hành các bước đánh giá chất lượng ban đầu.

Trong quá trình thực hiện, nhóm sử dụng tệp dữ liệu có tên adult(1).csv được cung cấp trong dự án. Đây là tệp dữ liệu thực tế dùng để đối chiếu với kết quả phân tích. Tuy nhiên, tài liệu hiện có chưa ghi nhận ngày tải xuống hoặc mã phiên bản phát hành cụ thể của tệp trên Kaggle, do đó nhóm không xác định thêm thông tin này.

1.2. Mục tiêu và ý nghĩa bộ dữ liệu

Bộ dữ liệu Adult Census Income được sử dụng nhằm phân tích đặc điểm của người lao động và tìm hiểu những yếu tố có mối liên hệ với mức thu nhập. Biến mục tiêu income phân chia người lao động thành hai nhóm:

+ <=50K: Người có thu nhập không vượt quá 50.000 USD.
+ >50K: Người có thu nhập trên 50.000 USD.

Thông qua việc phân tích các biến như độ tuổi, trình độ học vấn, giới tính, nghề nghiệp và số giờ làm việc mỗi tuần, nhóm hướng đến việc nhận diện sự khác biệt về đặc điểm giữa hai nhóm thu nhập.

Bộ dữ liệu có ý nghĩa trong việc minh họa cách sử dụng các phương pháp phân tích dữ liệu để khám phá mối liên hệ giữa đặc điểm cá nhân, nghề nghiệp và thu nhập. Kết quả có thể cung cấp thông tin tham khảo cho người lao động, doanh nghiệp và cơ quan hoạch định chính sách trong các vấn đề liên quan đến giáo dục, đào tạo và thị trường lao động.

1.3. Quy mô và cấu trúc dữ liệu

Kết quả kiểm tra tệp dữ liệu ban đầu cho thấy bộ dữ liệu gồm 32.561 dòng và 15 cột. Mỗi dòng tương ứng với một quan sát về cá nhân người lao động. Về kiểu dữ liệu, bộ dữ liệu gồm 6 biến định lượng có kiểu int64 và 9 biến định tính có kiểu object.

Các thuộc tính được phân thành những nhóm chính:

- Đặc điểm nhân khẩu học: độ tuổi, giới tính, chủng tộc, quốc gia xuất xứ.
- Đặc điểm học vấn: trình độ học vấn và số năm học.
- Đặc điểm việc làm: loại hình làm việc, nghề nghiệp, tình trạng hôn nhân và mối quan hệ gia đình.
- Đặc điểm tài chính: lãi vốn và lỗ vốn.

- Đặc điểm thời gian làm việc: số giờ làm việc mỗi tuần.
- Biến mục tiêu: nhóm thu nhập.

Tên thuộc tính	Ý nghĩa	Kiểu dữ liệu	Vai trò
age	độ tuổi	số nguyên	biến định lương
workclass	loại hình làm việc	phân loại	biến độc lập
fnlwgt	trọng số mẫu điều tra	số nguyên	biến định lương
education	trình độ học vấn	phân loại	biến độc lập
education.num	số năm học tương ứng với trình độ học vấn	số nguyên	biến định lương
martial.status	tình trạng hôn nhân	phân loại	biến độc lập
occupation	nghề nghiệp	phân loại	biến độc lập
relationship	mối quan hệ trong hộ gia đình	phân loại	biến độc lập
race	chủng tộc	phân loại	biến độc lập
sex	giới tính	phân loại	biến độc lập
capital.gain	lãi vốn	số nguyên	biến định lương
capital.loss	lỗ vốn	số nguyên	biến định lương
hours.per.week	số giờ làm việc mỗi tuần	số nguyên	biến định lương
native.country	quốc gia xuất xứ	phân loại	biến độc lập
income	nhóm thu nhập (≤50K hoặc >50K)	phân loại	biến mục tiêu

Bảng 1.1. Mô tả thuộc tính

1.4. Đánh giá chất lượng dữ liệu ban đầu

Trước khi tiến hành phân tích, nhóm thực hiện kiểm tra cấu trúc và chất lượng dữ liệu thông qua các phương thức như df.shape, df.info(), df.isnull().sum(), df.duplicated().sum() và kiểm tra ký hiệu "?" trong từng cột.

Thứ nhất, về quy mô dữ liệu:

- Số dòng: 32.561.
- Số cột: 15.
- Số biến định lượng: 6.
- Số biến định tính: 9.

Thứ hai, về kiểu dữ liệu:

- Các biến định lượng như age, fnlwgt, education.num, capital.gain, capital.loss và hours.per.week được lưu dưới dạng số nguyên. Các biến còn lại được lưu dưới dạng chuỗi ký tự.

- Cấu trúc này phù hợp với đặc điểm của dữ liệu điều tra, trong đó một số thuộc tính thể hiện bằng số, còn các thuộc tính khác được phân nhóm theo danh mục.

Thứ ba, về dữ liệu thiếu:

- Kết quả kiểm tra bằng df.isnull().sum() cho thấy dữ liệu ban đầu không có giá trị thiếu theo định dạng NaN. Tuy nhiên, khi kiểm tra sâu hơn, nhóm phát hiện ký hiệu ? được sử dụng để biểu thị thông tin chưa được ghi nhận trong ba thuộc tính:

Thuộc tính	Số ký hiệu ?
workclass	1.836
occupation	1.843
native.country	583
Tổng	4.262

- Như vậy, mặc dù kết quả kiểm tra NaN ban đầu bằng 0, dữ liệu vẫn tồn tại các giá trị chưa được ghi nhận dưới dạng ký hiệu ?.

Thứ tư, về dữ liệu trùng lặp:

- Kết quả kiểm tra cho thấy bộ dữ liệu có 24 dòng trùng lặp. Đây là vấn đề cần xử lý để hạn chế việc một quan sát bị tính nhiều lần trong quá trình thống kê.

Thứ năm, về giá trị bất thường và tính nhất quán:

- Nhóm sử dụng phương pháp IQR để rà soát giá trị ngoại lệ trong các biến định lượng. Kết quả cho thấy một số biến như age, fnlwgt, education.num, capital.gain, capital.loss và hours.per.week có giá trị vượt ngoài ngưỡng IQR.
- Bên cạnh đó, một số biến định tính có khoảng trắng ở đầu hoặc cuối giá trị. Nếu không được chuẩn hóa, những giá trị có cùng ý nghĩa nhưng khác định dạng có thể bị hệ thống xem là các nhóm riêng biệt.

1.5. Nhận xét giai đoạn 1:

- Qua quá trình đánh giá, nhóm nhận thấy bộ dữ liệu Adult Census Income có quy mô tương đối lớn, bao gồm 32.561 quan sát và 15 thuộc tính, đồng thời cung cấp nhiều thông tin về đặc điểm cá nhân, học vấn, nghề nghiệp và thu nhập.
- Tuy nhiên, dữ liệu ban đầu vẫn tồn tại một số vấn đề cần xử lý trước khi phân tích, bao gồm 4.262 ký hiệu thiếu ?, 24 dòng trùng lặp và một số giá trị ngoại lệ trong các biến định lượng. Ngoài ra, việc tồn tại khoảng trắng trong các biến định tính có thể ảnh hưởng đến quá trình phân nhóm và thống kê.
- Do đó, nhóm tiến hành tiền xử lý và làm sạch dữ liệu nhằm chuẩn hóa cấu trúc, xử lý thông tin chưa được ghi nhận và hạn chế ảnh hưởng của các quan sát trùng lặp, bất thường.

PHẦN 2. TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

2.1. Nguyên tắc và quy trình

- Quá trình tiền xử lý được thực hiện nhằm nâng cao chất lượng dữ liệu, hạn chế sai lệch trong quá trình phân tích và bảo đảm các bước xử lý có thể tái lập.
- Nhóm áp dụng nguyên tắc ưu tiên giữ lại các quan sát hợp lệ, hạn chế loại bỏ dữ liệu không cần thiết và chỉ điều chỉnh những giá trị được xác định là cần xử lý.
- Quy trình tiền xử lý được thực hiện theo thứ tự:

1. Nhận diện và xử lý các giá trị thiếu được biểu diễn bằng ký hiệu ?.
2. Kiểm tra và loại bỏ các dòng dữ liệu trùng lặp.
3. Phát hiện giá trị ngoại lệ bằng phương pháp IQR.
4. Thực hiện Winsorization đối với biến age.
5. Chuẩn hóa khoảng trắng trong các biến định tính.
6. Kiểm tra lại chất lượng dữ liệu và lưu dữ liệu sau làm sạch.

- Sau khi hoàn thành các bước trên, dữ liệu được sử dụng làm cơ sở cho hoạt động phân tích thống kê và trực quan hóa.

2.2. Xử lý dữ liệu thiếu

- Qua kiểm tra ban đầu, nhóm phát hiện ký hiệu ? xuất hiện trong ba thuộc tính workclass, occupation và native.country.
- Để xử lý, nhóm sử dụng Pandas chuyển toàn bộ ký hiệu ? thành giá trị thiếu chuẩn NaN thông qua phương thức replace().
- Sau đó, nhóm áp dụng phương pháp thay thế bằng giá trị xuất hiện nhiều nhất (Mode) cho từng thuộc tính:

Thuộc tính	Số giá trị thiếu ban đầu	Giá trị thay thế
workclass	1.836	Private
occupation	1.843	Prof-specialty
native.country	583	United-States
Tổng	4.262	

Phương pháp Mode được lựa chọn vì các thuộc tính này đều là biến định tính. Việc sử dụng giá trị xuất hiện nhiều nhất giúp duy trì số lượng quan sát ban đầu, tránh phải loại bỏ những dòng dữ liệu có thông tin thiếu. Sau khi thay thế, nhóm kiểm tra lại tổng số giá trị thiếu bằng df.isnull().sum(). Kết quả cho thấy dữ liệu không còn giá trị thiếu ở cả 15 thuộc tính. Tuy nhiên, cần lưu ý rằng phương pháp thay thế bằng Mode có thể làm tăng tỷ trọng của nhóm giá trị phổ biến nhất. Vì vậy, kết quả phân tích liên quan đến ba biến này cần được diễn giải thận trọng.

2.3. Xử lý dữ liệu trùng lặp

Sau khi xử lý dữ liệu thiếu, nhóm tiến hành kiểm tra số lượng dòng trùng lặp bằng phương thức df.duplicated().sum(). Kết quả cho thấy dữ liệu ban đầu có 24 dòng trùng lặp. Nhóm sử dụng phương thức drop_duplicates() để loại bỏ các bản ghi trùng, giữ lại một bản ghi đại diện cho mỗi quan sát duy nhất.

Kết quả sau xử lý:

- Số dòng trước khi loại bỏ trùng lặp: 32.561.
- Số dòng trùng lặp được loại bỏ: 24.
- Số dòng còn lại: 32.537.

Việc loại bỏ các bản ghi trùng lặp giúp hạn chế tình trạng một quan sát được tính nhiều lần, từ đó nâng cao độ tin cậy của các kết quả thống kê.

2.4. Chuẩn hóa định dạng và giá trị

Bên cạnh việc xử lý dữ liệu thiếu và trùng lặp, nhóm thực hiện chuẩn hóa khoảng trắng trong các biến định tính. Cụ thể, nhóm sử dụng phương thức str.strip() để loại bỏ khoảng trắng ở đầu và cuối chuỗi ký tự trong các cột có kiểu dữ liệu object. Bước này giúp những giá trị có cùng nội dung nhưng khác biệt về khoảng trắng được nhận diện thống nhất. Ví dụ, các giá trị " Private" và "Private" sẽ được chuẩn hóa thành cùng một nhãn "Private". Ngoài ra, nhóm thực hiện mã hóa biến mục tiêu income thành dạng nhị phân để thuận tiện cho việc tính toán tỷ lệ và phân tích:

- <=50K được mã hóa thành 0.
- >50K được mã hóa thành 1.

Việc mã hóa này chỉ được thực hiện trên bản dữ liệu phục vụ phân tích, không làm thay đổi ý nghĩa của hai nhóm thu nhập ban đầu.

2.5. Phát hiện và xử lý ngoại lệ

Nhóm sử dụng phương pháp khoảng tứ phân vị IQR (Interquartile Range) để phát hiện các giá trị ngoại lệ trong các biến định lượng. Công thức xác định khoảng tứ phân vị:

$$IQR = Q_3 - Q_1$$

Trong đó:

- Q_1: Tứ phân vị thứ nhất.
- Q_3: Tứ phân vị thứ ba.

Các ngưỡng phát hiện ngoại lệ được xác định như sau:

$$Lower = Q_1 - 1,5 \times IQR$$

$$Upper = Q_3 + 1,5 \times IQR$$

Nhóm sử dụng các ngưỡng này để rà soát giá trị bất thường trong các biến định lượng. Tuy nhiên, không phải mọi giá trị vượt ngưỡng IQR đều bị xem là sai lệch cần loại bỏ, bởi một số giá trị có thể phản ánh đặc điểm thực tế của người lao động. Trong phạm vi xử lý, nhóm lựa chọn biến age để thực hiện Winsorization đối với các giá trị vượt ngưỡng trên. Kết quả sau khi loại bỏ dòng trùng lặp và tính toán lại IQR cho biến age như sau:

Chỉ tiêu	**Giá trị**
Q1	28
Q3	48
IQR	20
Ngưỡng dưới	-2
Ngưỡng trên	78
Số giá trị vượt ngưỡng trên	142
Số giá trị vượt ngưỡng trên	142
Số giá trị được điều chỉnh	142
Giá trị lớn nhất sau xử lý	78

Nhóm sử dụng phương thức clip(upper=78) để điều chỉnh các quan sát có độ tuổi lớn hơn 78 về ngưỡng 78, thay vì loại bỏ hoàn toàn các quan sát này. Việc sử dụng Winsorization giúp hạn chế ảnh hưởng của các giá trị quá lớn trong quá trình tính toán, đồng thời giữ lại số lượng quan sát trong bộ dữ liệu. Cần lưu ý rằng nhóm chỉ thực hiện điều chỉnh ngoại lệ đối với phía trên của biến age. Các biến định lượng khác được rà soát bằng IQR nhưng không bị tự động loại bỏ hoặc điều chỉnh.

2.6. Đánh giá dữ liệu sau làm sạch

Sau khi hoàn thành các bước xử lý, nhóm tiến hành kiểm tra lại kích thước dữ liệu, số lượng giá trị thiếu và số dòng trùng lặp. Kết quả cho thấy dữ liệu sau làm sạch gồm 32.537 dòng và 15 cột, không còn giá trị thiếu và không còn dòng trùng lặp.

Chỉ tiêu	Trước xử lý	Sau xử lý
Số dòng	32.561	15
Số cột	15	0
Số giá trị thiếu chuẩn NaN	0	0

Số ký hiệu ?	4.262	0
Số dòng trùng	24	0
Số giá trị age vượt ngưỡng trên	142	

Bảng 2.1. So sánh trước và sau làm sạch

Ngoài ra, nhóm lưu dữ liệu sau tiền xử lý thành tệp adult_cleaned.csv trong thư mục Google Drive để phục vụ các bước phân tích tiếp theo.

2.7. Nhận xét giai đoạn 2

Quá trình tiền xử lý đã giúp dữ liệu được chuẩn hóa hơn so với ban đầu. Cụ thể, nhóm đã xử lý toàn bộ 4.262 ký hiệu thiếu, loại bỏ 24 dòng trùng lặp và điều chỉnh 142 giá trị độ tuổi vượt ngưỡng trên 78. Sau khi làm sạch, bộ dữ liệu còn 32.537 quan sát và 15 thuộc tính, không còn giá trị thiếu hoặc dòng trùng lặp. Số lượng quan sát được giữ lại ở mức cao, hạn chế tình trạng mất thông tin do loại bỏ dữ liệu hàng loạt. Như vậy, dữ liệu sau làm sạch được sử dụng làm cơ sở cho Phần 3 nhằm phân tích đặc điểm của hai nhóm thu nhập và kiểm định các giả thuyết nghiên cứu.

PHẦN 3. PHÂN TÍCH VÀ TRỰC QUAN HÓA

3.1. Phương pháp phân tích

Sau khi hoàn thành tiền xử lý, nhóm tiến hành phân tích dữ liệu nhằm tìm hiểu phân phối thu nhập và mối liên hệ giữa các đặc điểm cá nhân, nghề nghiệp với nhóm thu nhập. Các phương pháp được sử dụng bao gồm:

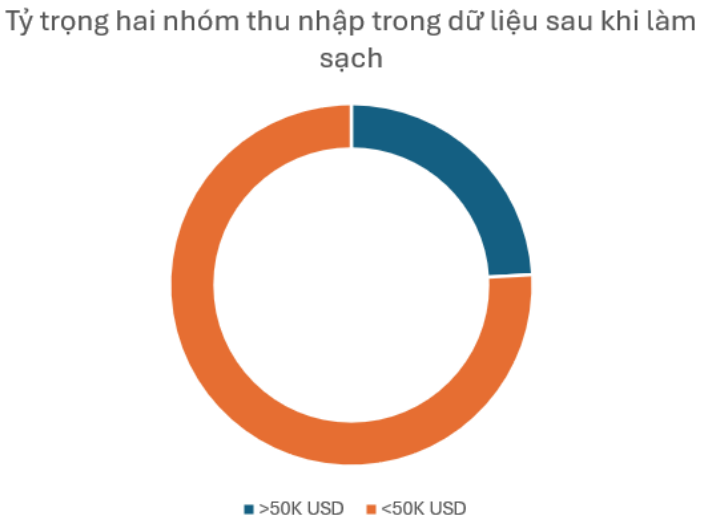
- Thống kê mô tả: Sử dụng số lượng, tỷ lệ phần trăm, trung bình và trung vị để mô tả phân phối dữ liệu và so sánh đặc điểm giữa hai nhóm thu nhập.
- Trực quan hóa dữ liệu: Sử dụng biểu đồ cột để thể hiện tỷ lệ thu nhập theo trình độ học vấn và nghề nghiệp; biểu đồ phân phối để so sánh độ tuổi; biểu đồ hộp để thể hiện sự phân bố số giờ làm việc giữa hai nhóm.
- Phân tích tương quan: Sử dụng hệ số tương quan Spearman để đánh giá mức độ và chiều hướng tương quan đơn điệu giữa các biến định lượng.
- Kiểm định giả thuyết: Sử dụng Chi-square cho các biến định tính và Mann-Whitney U cho các biến định lượng khi so sánh hai nhóm thu nhập độc lập.
- Mức ý nghĩa thống kê được lựa chọn là 5% ($\alpha = 0,05$).

3.2. Phân phối nhóm thu nhập

Nhóm tiến hành phân tích phân phối của biến mục tiêu income nhằm xác định số lượng và tỷ trọng người lao động thuộc từng nhóm thu nhập. Kết quả thu được:

Nhóm thu nhập	Số lượng	Tỷ lệ
≤50K USD	24.698	75,91%
>50K USD	7.839	24,09%
Tổng	32.537	100%

Bảng 3.2. Phân phối người lao động theo nhóm thu nhập



Biểu đồ 3.2. Phân phối người lao động theo nhóm thu nhập

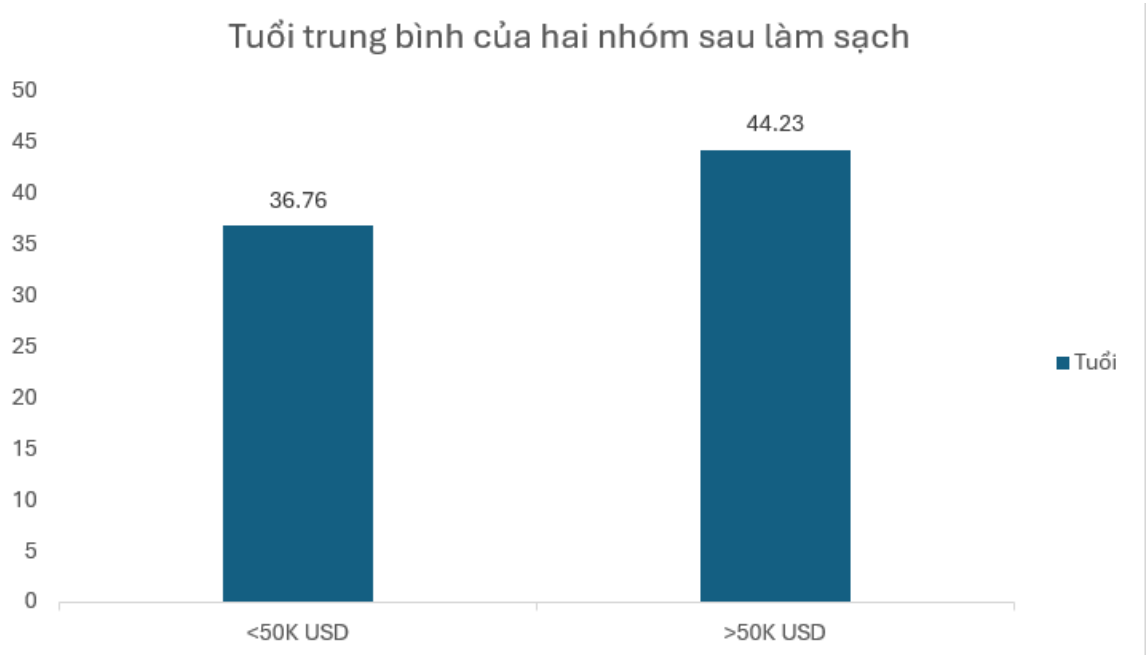
Kết quả cho thấy nhóm người lao động có thu nhập không vượt quá 50.000 USD chiếm tỷ trọng lớn nhất, đạt 75,91% tổng số quan sát. Trong khi đó, nhóm có thu nhập trên 50.000 USD chỉ chiếm 24,09%. Như vậy, bộ dữ liệu có sự chênh lệch tương đối rõ rệt về quy mô giữa hai nhóm thu nhập. Đây là đặc điểm cần lưu ý trong quá trình phân tích và diễn giải kết quả, đặc biệt nếu sử dụng dữ liệu để xây dựng mô hình phân loại ở các bước tiếp theo.

3.3. Độ tuổi và thu nhập

Để tìm hiểu sự khác biệt về độ tuổi giữa hai nhóm thu nhập, nhóm sử dụng biểu đồ phân phối độ tuổi kết hợp với các chỉ tiêu thống kê mô tả.

Chỉ tiêu	≤50K USD	>50K USD
Số quan sát	24.698	7.839
Tuổi trung bình	36,76	44,23
Tuổi trung vị	34	44

Bảng 3.3. So sánh độ tuổi theo nhóm thu nhập



Biểu đồ 3.3. Tuổi trung bình theo nhóm thu nhập

Kết quả cho thấy nhóm có thu nhập trên 50.000 USD có tuổi trung bình đạt 44,23, cao hơn nhóm thu nhập không vượt quá 50.000 USD với mức 36,76 tuổi. Tương tự, tuổi trung vị của nhóm thu nhập cao là 44 tuổi, trong khi nhóm còn lại là 34 tuổi. Sự khác biệt này cho thấy nhóm có thu nhập cao trong bộ dữ liệu có xu hướng tập trung ở độ tuổi lớn hơn.Tuy nhiên, kết quả thống kê mô tả chưa đủ để khẳng định

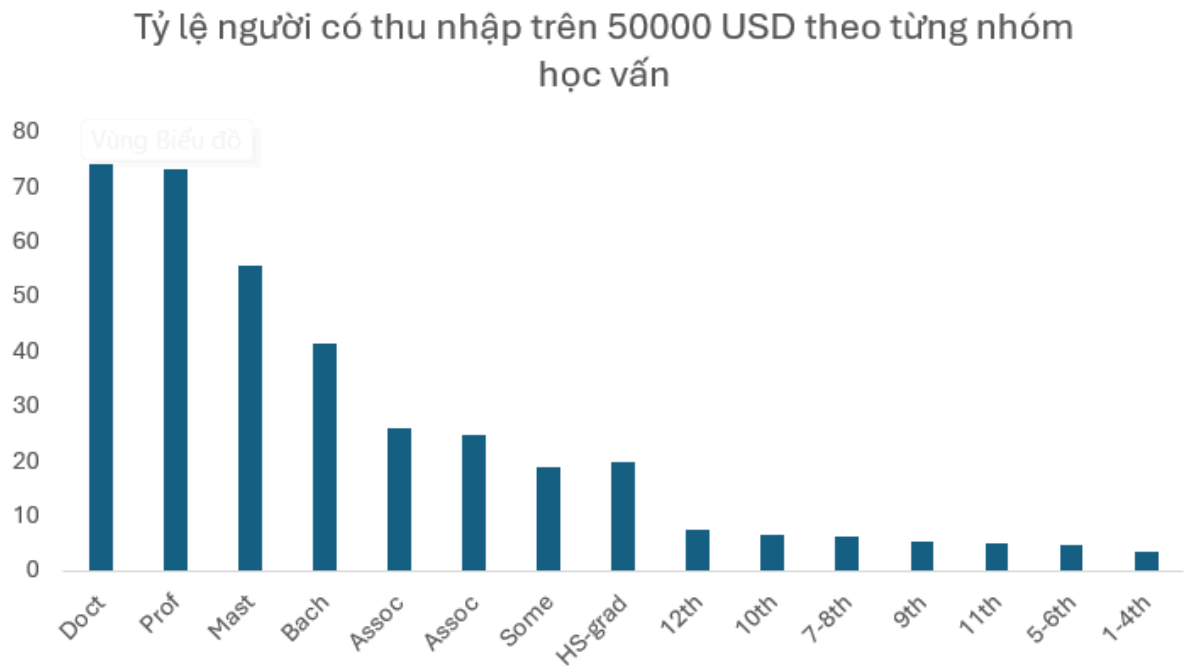
tuổi tác là nguyên nhân làm tăng thu nhập. Sự khác biệt có thể đồng thời liên quan đến kinh nghiệm làm việc, trình độ học vấn, nghề nghiệp và các đặc điểm khác.

3.4. Trình độ học vấn và thu nhập

Nhóm phân tích tỷ lệ người lao động có thu nhập trên 50.000 USD trong từng nhóm trình độ học vấn. Việc sử dụng tỷ lệ phần trăm thay vì chỉ so sánh số lượng tuyệt đối giúp hạn chế ảnh hưởng của sự khác biệt về quy mô giữa các nhóm học vấn.

Trình độ học vấn	Tỷ lệ >50K
Doctorate	74,09%
Prof-school	73,44%
Masters	55,69%
Bachelors	26,12%
Assoc-acdm	24,84%
Some-college	19,03%
HS-grad	15,95%
12th	7,62%
10th	6,65%
7th-8th	6,20%
9th	5,25%
11th	5,11%
5th-6th	4,82%
1st-4th	3,61%
Preschool	0,00%

Bảng 3.4. Tỷ lệ người lao động có thu nhập trên 50K theo trình độ học vấn



Biểu đồ 3.4. Tỷ lệ người có thu nhập trên 50K theo học vấn

Kết quả cho thấy tỷ lệ người lao động có thu nhập trên 50.000 USD có xu hướng cao hơn ở các nhóm có trình độ học vấn cao. Cụ thể, Doctorate và Prof-school là hai nhóm có tỷ lệ cao nhất, lần lượt đạt 74,09% và 73,44%. Nhóm Masters đạt 55,69%, trong khi nhóm Bachelors đạt 41,49%. Ngược lại, các nhóm có trình độ học vấn thấp hơn như 1st-4th, 5th-6th và 11th có tỷ lệ thu nhập trên 50.000 USD dưới 6%. Kết quả mô tả cho thấy trình độ học vấn có mối liên hệ đáng chú ý với phân phối thu nhập. Tuy nhiên, đây mới là sự khác biệt về tỷ lệ giữa các nhóm, chưa thể kết luận trình độ học vấn trực tiếp quyết định mức thu nhập của người lao động.

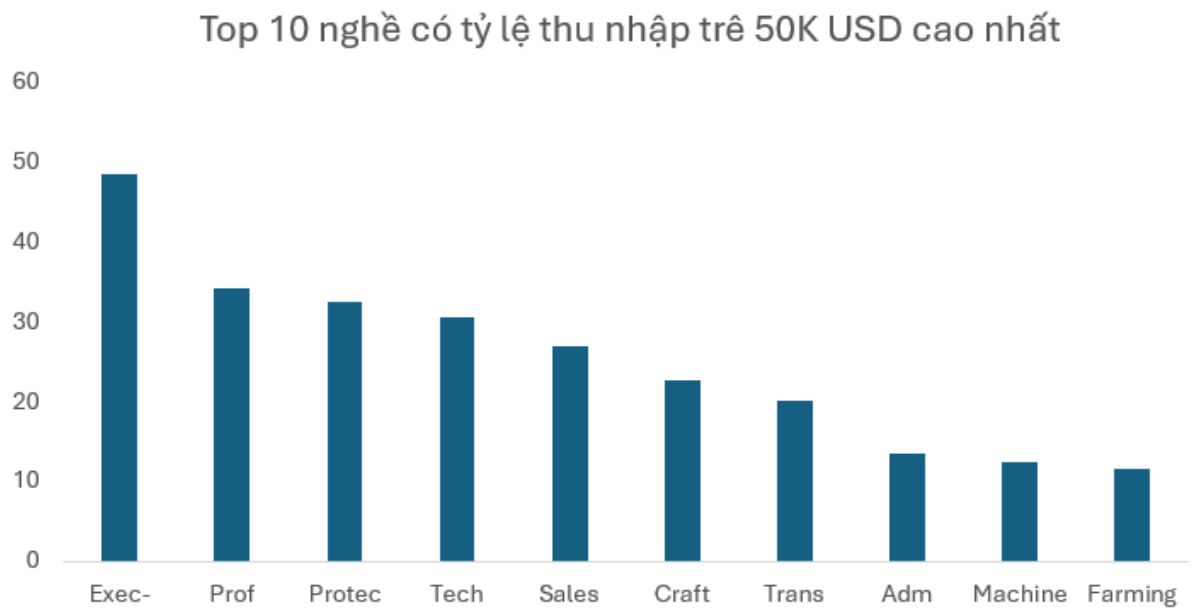
3.5. Nghề nghiệp và thu nhập

Để đánh giá sự khác biệt về thu nhập giữa các nhóm nghề nghiệp, nhóm tính tỷ lệ người lao động có thu nhập trên 50.000 USD trong từng nhóm. Trong biểu đồ Top 10 nhóm nghề nghiệp, nhóm chỉ giữ lại những nghề có ít nhất 30 quan sát nhằm hạn chế việc diễn giải các tỷ lệ được tính từ quy mô mẫu quá nhỏ.

Nghề nghiệp	Số quan sát	Tỷ lệ >50K
Exec-managerial	4.065	48,41%
Prof-specialty	5.979	34,27%
Protective-serv	649	32,51%
Tech-support	927	30,53%

Sales	3.650	26,93%
Craft-repair	4.094	22,69%
Transport-moving	1.597	20,04%
Adm-clerical	3.768	13,46%
Machine-op-inspct	2.000	12,45%
Farming-fishing	992	11,59%

Bảng 3.5. Top 10 nhóm nghề nghiệp có tỷ lệ thu nhập trên 50K cao nhất



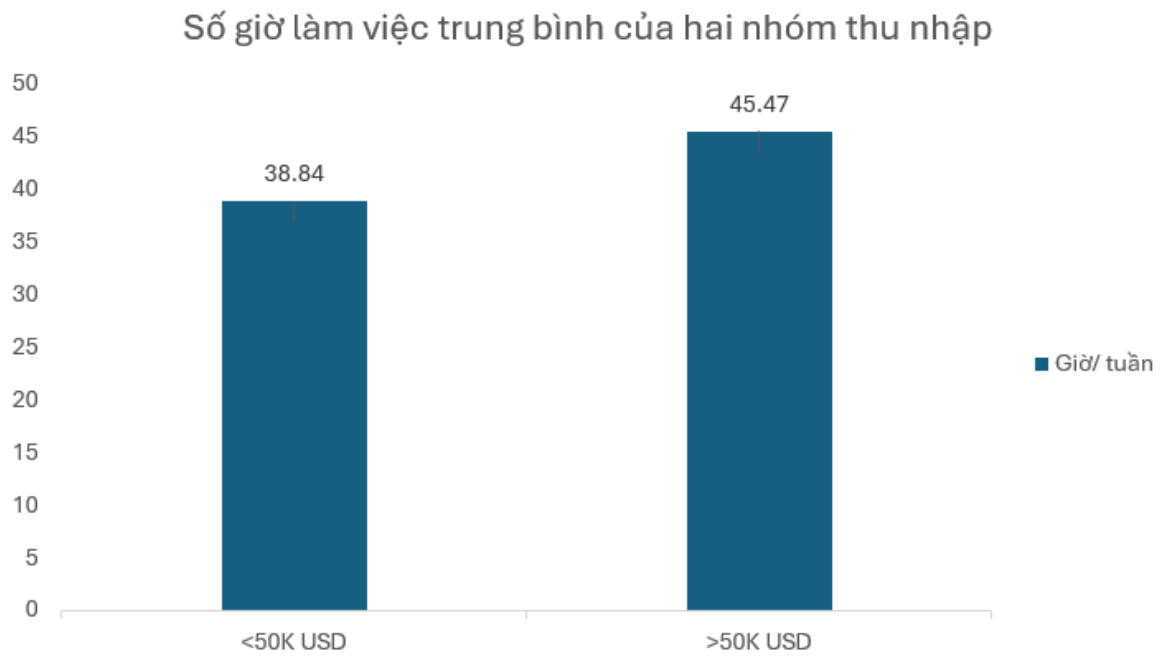
Biểu đồ 3.5.Tỷ lệ thu nhập trên 50K theo nghề nghiệp

3.6. Số giờ làm việc và thu nhập

Nhóm tiếp tục phân tích số giờ làm việc mỗi tuần (hours.per.week) nhằm tìm hiểu sự khác biệt giữa hai nhóm thu nhập.

Chỉ tiêu	≤50K USD	>50K USD
Số quan sát	24.698	7.839
Số giờ trung bình/tuần	38,84	45,47
Số giờ trung vị/tuần	40	40

Bảng 3.6. So sánh số giờ làm việc theo nhóm thu nhập



Biểu đồ 3.6. Số giờ làm việc trung bình mỗi tuần

Kết quả cho thấy nhóm có thu nhập trên 50.000 USD làm việc trung bình 45,47 giờ mỗi tuần, cao hơn nhóm thu nhập không vượt quá 50.000 USD với mức 38,84 giờ. Tuy nhiên, trung vị số giờ làm việc của cả hai nhóm đều bằng 40 giờ/tuần. Điều này cho thấy sự khác biệt về số giờ làm việc giữa hai nhóm thể hiện rõ hơn ở giá trị trung bình và phân phối tổng thể, thay vì trung vị. Kết quả bước đầu gợi ý rằng số giờ làm việc có mối liên hệ với nhóm thu nhập. Để đánh giá sự khác biệt này có ý nghĩa thống kê hay không, nhóm tiếp tục thực hiện kiểm định Mann-Whitney U.

3.7. Tương quan giữa biến định lượng

Nhóm sử dụng hệ số tương quan Spearman để đánh giá mối tương quan đơn điệu giữa các biến định lượng trong bộ dữ liệu. Phương pháp Spearman được lựa chọn vì không yêu cầu mối quan hệ giữa hai biến phải là tuyến tính và ít phụ thuộc hơn vào giả định phân phối chuẩn so với tương quan Pearson. Các biến được đưa vào ma trận tương quan gồm age, fnlwgt, education.num, capital.gain, capital.loss, hours.per.week và income_binary.

Biến	Hệ số Spearman với income_binary
education.num	0,330
capital.gain	0,278
age	0,273

hours.per.week	0,269
capital.loss	0,141
fnlwgt	-0,011

Bảng 3.7. Một số hệ số tương quan Spearman với biến thu nhập

Kết quả cho thấy education.num có hệ số tương quan dương lớn nhất với biến thu nhập, đạt 0,330. Tiếp theo là capital.gain với 0,278, age với 0,273 và hours.per.week với 0,269. Trong khi đó, fnlwgt có hệ số tương quan rất gần 0, đạt -0,011, cho thấy tương quan đơn điệu giữa biến này và nhóm thu nhập trong dữ liệu là rất yếu. Nhìn chung, các hệ số tương quan cho thấy trình độ học vấn, độ tuổi, lãi vốn và số giờ làm việc có tương quan dương với biến thu nhập đã mã hóa. Tuy nhiên, tương quan không chứng minh quan hệ nhân quả và cũng không phản ánh tác động riêng biệt của từng biến khi các yếu tố khác chưa được kiểm soát.

3.8. Kiểm định giả thuyết thống kê

Với 3 mối quan hệ được kiểm định bằng Chi-square trong kết quả phân tích, bảng sẽ trình bày như sau:

Mối quan hệ	Kiểm định	Thống kê	p-value	Kết luận
Trình độ học vấn và mức thu nhập	Chi-square (χ^2)	4428.405 (df = 15)	< 0.001	H_0: Hai biến độc lập. H_1: Hai biến có mối liên hệ. Với $\alpha = 0.05$, bác bỏ H_0. Có mối liên hệ có ý nghĩa thống kê giữa trình độ học vấn và thu nhập; cỡ mẫu N = 32,537.
Giới tính và mức thu nhập	Chi-square (χ^2)	1516.540 (df = 1)	< 0.001	H_0: Hai biến độc lập. H_1: Hai biến có mối liên hệ. Với $\alpha = 0.05$, bác bỏ H_0. Có mối liên hệ có ý nghĩa thống

				kê giữa giới tính và thu nhập; cỡ mẫu N = 32,537.
Nghề nghiệp và mức thu nhập	Chi-square (χ^2)	3197.613 (df = 13)	< 0.001	H_0: Hai biến độc lập. H_1: Hai biến có mối liên hệ. Với $\alpha = 0.05$, bác bỏ H_0. Có mối liên hệ có ý nghĩa thống kê giữa nghề nghiệp và thu nhập; cỡ mẫu N = 32,537.

3.9. Tổng hợp phát hiện

Từ kết quả phân tích thống kê mô tả, trực quan hóa và kiểm định giả thuyết, nhóm rút ra một số phát hiện chính:

Thứ nhất, bộ dữ liệu có sự chênh lệch rõ rệt về phân phối thu nhập. Nhóm có thu nhập không vượt quá 50.000 USD chiếm 75,91%, trong khi nhóm thu nhập trên 50.000 USD chiếm 24,09%.

Thứ hai, nhóm có thu nhập trên 50.000 USD có tuổi trung bình và trung vị cao hơn nhóm còn lại. Cụ thể, tuổi trung bình đạt 44,23 so với 36,76 và tuổi trung vị đạt 44 so với 34.

Thứ ba, tỷ lệ thu nhập trên 50.000 USD có xu hướng cao hơn ở các nhóm có trình độ học vấn cao. Doctorate và Prof-school là hai nhóm có tỷ lệ cao nhất, lần lượt đạt 74,09% và 73,44%.

Thứ tư, tỷ lệ thu nhập trên 50.000 USD có sự khác biệt giữa các nhóm nghề nghiệp. Exec-managerial có tỷ lệ cao nhất trong nhóm nghề nghiệp được phân tích, đạt 48,41%.

Thứ năm, nhóm thu nhập trên 50.000 USD có số giờ làm việc trung bình cao hơn, đạt 45,47 giờ/tuần so với 38,84 giờ/tuần ở nhóm còn lại. Tuy nhiên, trung vị của cả hai nhóm đều bằng 40 giờ/tuần.

Cuối cùng, kết quả kiểm định cho thấy cả năm giả thuyết nghiên cứu đều được ủng hộ ở mức ý nghĩa 5%. Điều này củng cố nhận định rằng các đặc điểm cá nhân và nghề nghiệp được lựa chọn có mối liên hệ hoặc sự khác biệt đáng kể với nhóm thu nhập trong bộ dữ liệu.

PHẦN 4. ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

4.1. Ý nghĩa của kết quả

Kết quả phân tích cho thấy thu nhập của người lao động có mối liên hệ với nhiều đặc điểm cá nhân và nghề nghiệp, bao gồm trình độ học vấn, giới tính, độ tuổi, nghề nghiệp và số giờ làm việc. Những phát hiện này có thể mang lại một số ý nghĩa tham khảo đối với người lao động, doanh nghiệp và cơ quan hoạch định chính sách.

Đối với người lao động, kết quả cho thấy nhóm có trình độ học vấn cao hơn thường có tỷ lệ thu nhập trên 50.000 USD lớn hơn. Điều này gợi ý vai trò của giáo dục và trình độ chuyên môn trong việc mở rộng cơ hội nghề nghiệp và tiếp cận các công việc có mức thu nhập cao. Bên cạnh đó, sự khác biệt về độ tuổi giữa hai nhóm thu nhập cho thấy kinh nghiệm và quá trình tích lũy nghề nghiệp có thể là những khía cạnh đáng quan tâm khi nghiên cứu thu nhập. Tuy nhiên, dữ liệu hiện tại chưa trực tiếp đo lường kinh nghiệm làm việc nên chưa thể khẳng định tác động của yếu tố này.

Đối với doanh nghiệp, sự khác biệt về tỷ lệ thu nhập giữa các nhóm nghề nghiệp cho thấy đặc điểm công việc và vị trí nghề nghiệp cần được xem xét khi xây dựng chính sách tuyển dụng, đào tạo và đãi ngộ. Ngoài ra, kết quả về số giờ làm việc cho thấy nhóm có thu nhập cao hơn cũng có số giờ làm việc trung bình lớn hơn. Tuy nhiên, doanh nghiệp không nên chỉ dựa vào thời gian làm việc để đánh giá năng suất hoặc xác định mức lương, mà cần xem xét thêm tính chất công việc, trình độ chuyên môn và hiệu quả thực hiện công việc.

Đối với cơ quan hoạch định chính sách, kết quả phân tích gợi ý tầm quan trọng của việc mở rộng cơ hội tiếp cận giáo dục, đào tạo nghề và nâng cao kỹ năng chuyên môn cho người lao động.Bên cạnh đó, sự khác biệt về thu nhập giữa các nhóm nghề nghiệp và giới tính là cơ sở tham khảo để cơ quan quản lý tiếp tục quan tâm đến cơ hội việc làm, khả năng tiếp cận đào tạo và tính công bằng trong thị trường lao động.
Các đề xuất trên chỉ mang tính định hướng tham khảo từ kết quả phân tích, không phải kết luận nhân quả được chứng minh bởi bộ dữ liệu.

4.2. Khuyến nghị

Từ những kết quả phân tích, nhóm đề xuất một số khuyến nghị như sau:

a) Đối với người lao động

- Chủ động nâng cao trình độ học vấn và trình độ chuyên môn thông qua các chương trình giáo dục, đào tạo nghề và học tập liên tục.
- Tăng cường kỹ năng chuyên môn và kỹ năng thực hành phù hợp với yêu cầu của từng ngành nghề.

- Quan tâm đến việc lựa chọn và phát triển nghề nghiệp dựa trên năng lực, sở trường và cơ hội việc làm.
- Chú trọng hiệu quả và chất lượng công việc thay vì chỉ tập trung gia tăng số giờ làm việc.

b) Đối với doanh nghiệp

- Xây dựng các chương trình đào tạo và phát triển kỹ năng nhằm nâng cao năng lực chuyên môn của người lao động.
- Xây dựng chính sách tuyển dụng và phát triển nghề nghiệp dựa trên năng lực, trình độ và yêu cầu thực tế của vị trí công việc.
- Thiết lập cơ chế đánh giá, trả lương và đãi ngộ minh bạch, phù hợp với tính chất công việc và hiệu quả đóng góp.
- Quan tâm đến việc cân bằng thời gian làm việc và hiệu suất lao động, tránh đánh đồng số giờ làm việc với năng suất.

c) Đối với cơ quan hoạch định chính sách

- Tăng cường khả năng tiếp cận giáo dục và đào tạo nghề, đặc biệt đối với nhóm lao động có trình độ học vấn thấp.
- Phát triển các chương trình đào tạo kỹ năng gắn với nhu cầu thực tế của thị trường lao động.
- Nâng cao chất lượng thông tin thị trường lao động, giúp người lao động tiếp cận thông tin về nghề nghiệp, yêu cầu tuyển dụng và mức thu nhập.
- Tiếp tục thúc đẩy các chính sách bảo đảm cơ hội việc làm bình đẳng và hạn chế chênh lệch thu nhập không hợp lý giữa các nhóm lao động.

4.3. Hạn chế nghiên cứu

Mặc dù đã thực hiện các bước tiền xử lý, thống kê mô tả và kiểm định giả thuyết, bài nghiên cứu vẫn tồn tại một số hạn chế.

Thứ nhất, hạn chế về phạm vi và tính cập nhật của dữ liệu. Bộ dữ liệu chỉ phản ánh những quan sát được cung cấp trong tập Adult Census Income. Thời điểm dữ liệu không được ghi rõ trong tệp nhóm sử dụng, vì vậy kết quả không thể được xem là đại diện cho tình hình thu nhập của lực lượng lao động hiện nay.

Thứ hai, hạn chế về các biến quan sát.Bộ dữ liệu có nhiều thông tin về đặc điểm cá nhân và nghề nghiệp, nhưng chưa phản ánh đầy đủ những yếu tố có thể liên quan đến thu nhập như kinh nghiệm làm việc thực tế, năng lực chuyên môn, năng suất lao động, quy mô doanh nghiệp và điều kiện kinh tế tại từng khu vực.

Thứ ba, hạn chế trong xử lý dữ liệu thiếu. Nhóm sử dụng phương pháp Mode để thay thế các giá trị thiếu trong ba biến định tính. Mặc dù phương pháp này giúp giữ

lại số lượng quan sát, việc thay thế có thể làm tăng tần suất của những nhóm giá trị phổ biến và ảnh hưởng đến phân phối ban đầu của dữ liệu.

Thứ tư, hạn chế trong xử lý ngoại lệ. Nhóm chỉ thực hiện Winsorization đối với các giá trị vượt ngưỡng trên của biến age. Những biến định lượng khác được rà soát bằng phương pháp IQR nhưng không được điều chỉnh. Vì vậy, ảnh hưởng của các giá trị cực đoan trong những biến này vẫn có thể tồn tại.

Thứ năm, hạn chế về phương pháp phân tích. Các kiểm định Chi-square và Mann-Whitney U chỉ đánh giá mối liên hệ hoặc sự khác biệt giữa các biến. Nhóm chưa thực hiện mô hình phân tích đa biến để kiểm soát đồng thời ảnh hưởng của nhiều yếu tố, do đó chưa xác định được tác động riêng biệt của từng biến đối với thu nhập.

Ngoài ra, nhóm đã thực hiện mã hóa, chuẩn hóa và chia dữ liệu thành tập Train và Test, nhưng chưa tiến hành huấn luyện và đánh giá mô hình học máy. Vì vậy, bài nghiên cứu chưa có kết quả dự đoán nhóm thu nhập.

4.4. Hướng nghiên cứu tiếp theo

Từ những hạn chế trên, các nghiên cứu tiếp theo có thể mở rộng theo một số hướng:

- Sử dụng dữ liệu cập nhật hơn để phản ánh sát hơn tình hình thu nhập và đặc điểm thị trường lao động.
- Bổ sung các biến như kinh nghiệm làm việc, năng lực chuyên môn, khu vực sinh sống và đặc điểm doanh nghiệp nhằm phân tích toàn diện hơn các yếu tố liên quan đến thu nhập.
- Áp dụng các phương pháp xử lý dữ liệu thiếu và ngoại lệ khác nhau để so sánh mức độ ảnh hưởng đến kết quả phân tích.
- Sử dụng hồi quy Logistic hoặc các phương pháp phân tích đa biến để đánh giá mối liên hệ giữa nhiều yếu tố với nhóm thu nhập trong cùng một mô hình.
- Xây dựng các mô hình học máy như Logistic Regression, Decision Tree và Random Forest để dự đoán nhóm thu nhập, đồng thời so sánh hiệu quả bằng các chỉ số Accuracy, Precision, Recall, F1-score và ROC-AUC.
- Mở rộng phạm vi nghiên cứu bằng cách so sánh sự khác biệt về thu nhập giữa các nhóm dân cư, ngành nghề hoặc quốc gia nếu có nguồn dữ liệu phù hợp.

KẾT LUẬN

Bài nghiên cứu đã sử dụng bộ dữ liệu Adult Census Income để phân tích các đặc điểm cá nhân và nghề nghiệp có mối liên hệ với nhóm thu nhập của người lao động. Quá trình nghiên cứu được thực hiện thông qua các bước thu thập và đánh giá dữ liệu, tiền xử lý, thống kê mô tả, trực quan hóa và kiểm định giả thuyết. Sau khi xử lý 4.262 ký hiệu thiếu và loại bỏ 24 dòng trùng lặp, bộ dữ liệu còn 32.537 quan sát và 15 thuộc tính, không còn giá trị thiếu hoặc dòng trùng lặp.

Kết quả phân tích cho thấy nhóm thu nhập không vượt quá 50.000 USD chiếm 75,91%, trong khi nhóm thu nhập trên 50.000 USD chiếm 24,09%. Nhóm thu nhập cao có tuổi trung bình, trình độ học vấn trung bình và số giờ làm việc trung bình lớn hơn nhóm còn lại. Đồng thời, tỷ lệ thu nhập trên 50.000 USD có sự khác biệt đáng kể giữa các nhóm trình độ học vấn và nghề nghiệp. Kết quả kiểm định Chi-square và Mann-Whitney U cho thấy cả năm giả thuyết nghiên cứu đều được ủng hộ ở mức ý nghĩa 5%. Điều này cung cấp bằng chứng thống kê về mối liên hệ giữa trình độ học vấn, giới tính, nghề nghiệp và thu nhập, cũng như sự khác biệt về độ tuổi và số giờ làm việc giữa hai nhóm thu nhập.

Nhìn chung, nghiên cứu đã minh họa cách vận dụng các phương pháp xử lý và phân tích dữ liệu để khám phá những đặc điểm liên quan đến thu nhập của người lao động. Tuy nhiên, do giới hạn về dữ liệu và phương pháp, các kết quả chỉ phản ánh mối liên hệ thống kê, chưa chứng minh quan hệ nhân quả. Đây cũng là cơ sở để nhóm tiếp tục mở rộng nghiên cứu bằng các phương pháp phân tích đa biến và mô hình dự đoán trong tương lai.

TÀI LIỆU THAM KHẢO

1. Kaggle. (n.d.). Adult Census Income. https://www.kaggle.com/datasets/uciml/adult-census-income.
2. McKinney, W. (2010). Data structures for statistical computing in Python. Proceedings of the 9th Python in Science Conference, 56-61.
3. Virtanen, P., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. Nature Methods, 17, 261-272.
4. Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

PHỤ LỤC

Phụ lục 1. **Mã nguồn và dữ liệu**

1. Tệp dữ liệu gốc: adult.csv.
2. Tệp mã nguồn Python: adult_census_income_analysis.py.
3. Notebook Google Colab: Adult_Census_Income_Analysis.ipynb.
4. Tệp kết quả phân tích: Adult_Census_Analysis_Results.xlsx.

Phụ lục 2. Đường dẫn dự án

1. GitHub Public: https://github.com/nguyenminhquynhanh21/KHOA-HOC-DU-LIEU-MIDTERM-GROUP_14
2. Google Colab: https://colab.research.google.com/drive/1QBunQ9EMFwwnvo03pu7nJ32Nb_xmp8cm#scrollTo=PnMv5NQOefTL